

DF : Data frame

VC : Variable categórica

VN : Variable numérica

CARGA DE LIBRERÍAS, BASE DE DATOS Y LIMPIEZA DE algunos DATOS

Carga de librerías

```
library(readr)
```

```
library(dplyr)
```

```
library(modeest)
```

```
library(ggplot2)
```

Carga de Base de Datos

```
DF <- read_csv("Base_datos.csv")
```

Limpieza de datos

```
DF[ fila , columna ] <- valor numérico correcto      (cuando se tenga que corregir el  
teipoe de un número)
```

```
DF[ fila , columna ] <- NA      (cuando un valor está fuera de la realidad o tienen  
caracteres o símbolos raros y por tanto se cambia a NA)
```

Para una **variable numérica (VN)**

Inspeccionar los datos con la siguiente función, a fin de ver si los valores **mínimo y máximo** están dentro del rango de valores reales de la variable

```
summary(DF$VN)
```

Limpiar una variable numérica (VN)

Para que esté dentro de un rango real: $\text{ValorMinimo} \leq \text{VN} \leq \text{ValorMaximo}$

```
DF %>% mutate( VN =  
  ifelse(VN < ValorMinimo, NA,  
  ifelse(VN > ValorMaximo, NA,  
  VN ))) -> DF
```

DATOS FALTANTES

Número de filas, unidades muestrales u observaciones

```
nrow(DF)
```

Número de columnas o variables

```
ncol(DF)
```

Cantidad de datos faltantes

```
sum(is.na(DF))
```

Porcentaje de datos faltantes

```
round(sum(is.na(DF))/(nrow(DF)*ncol(DF))*100,2)
```

Cantidad de datos faltantes por variable

```
colSums(is.na(DF))
```

Porcentaje de datos faltantes por variable (redondeado a dos decimales)

```
round(colSums(is.na(DF))/nrow(DF)*100,2)
```

Cantidad de observaciones, unidades muestrales o filas completas sin datos faltantes.

```
sum(complete.cases(DF))
```

Porcentaje de observaciones, unidades muestrales o filas completas sin datos faltantes (redondeado a dos decimales)

```
round(sum(complete.cases(DF))/nrow(DF)*100, 2)
```

Cantidad de observaciones, unidades muestrales o filas incompletas con datos faltantes.

```
sum(!complete.cases(DF))
```

Porcentaje de observaciones, unidades muestrales o filas incompletas con datos faltantes (redondeado a dos decimales)

```
round(sum(!complete.cases(DF))/nrow(DF)*100, 2)
```

Tabla con cantidad de datos faltantes por fila, observación

```
table(rowSums(is.na(DF)))
```

Promedio de datos faltantes por fila, observación (redondeado a dos decimales)

```
round(mean(rowSums(is.na(DF))), 2)
```

Mediana de datos faltantes por fila, observación

```
median(rowSums(is.na(DF)))
```

OTROS CÁLCULOS

Cantidad de datos completos por columna o variable

```
tabla <- colSums(!is.na(DF))
```

Tamaño efectivo de la muestra

```
tamaño_muestra <- sum(complete.cases(DF))
```

Menor tamaño efectivo de la muestra

```
menor_muestra <- min(colSums(!is.na(DF)))
```

Nombre de la variable con menor tamaño efectivo de la muestra

```
nombre_variable <- names(tabla)[menor_muestra == tabla]
```

DESCRIPTORES DE POSICIÓN

Para variables numéricas (VN)

Valor mínimo y valor máximo

```
range(DF$VN, na.rm = T)
```

Valor mínimo

```
min(DF$VN, na.rm = TRUE)
```

Valor máximo

```
max(DF$VN, na.rm = TRUE)
```

Mediana

```
median(DF$VN, na.rm = TRUE)
```

Media (redondeado a dos decimales)

```
round(mean(DF$VN, na.rm = TRUE), 2)
```

Moda

```
which.max(table(DF$VN))      (una forma)
```

```
mfv(DF$VN, na_rm = T)        (otra forma con librería modeest)
```

Cálculo del Cuartil 1 = percentil 25 (Q1 = P25), cuartil 3 = percentil 75 (Q3 = P75)

```
quantile(DF$VN, c(0.25, 0.75), type=3, na.rm = TRUE)
```

Para una variable numérica: valor mínimo, máximo, media, mediana, nro. de datos faltantes

```
summary(DF$VN)
```

DESCRIPTORES DE DISPERSIÓN

Para variables numéricas (VN)

Rango

```
diff(range(DF$VN, na.rm=T))
```

Rango Intercuartil

```
IQR(DF$VN, type=3, na.rm = TRUE)      (una forma)
```

```
diff(quantile(DF$VN, c(0.25, 0.75), type=3, na.rm = TRUE))  (otra forma)
```

Varianza (redondeado a dos decimales)

```
round(var(DF$VN, na.rm = TRUE), 2)
```

Desviación estándar (redondeado a dos decimales)

```
round(sd(DF$VN, na.rm = TRUE), 2)
```

Coefficiente de variabilidad (redondeado a dos decimales)

```
round(sd(DF$VN, na.rm = TRUE)/mean(DF$VN, na.rm = TRUE), 2)
```

- Menor o igual a 0.3 → DISPERSIÓN BAJA,
- Mayor que 0.3 y menor o igual a 0.6 → DISPERSIÓN MEDIA,
- Mayor que 0.6 → DISPERSIÓN ALTA.

Fracción de dispersión (redondeado a dos decimales)

```
round(IQR(DF$VN, type=3, na.rm = TRUE)/ diff(range(DF$VN, na.rm=T)), 2)
```


- Menor o igual a 0.3 → DISPERSIÓN BAJA,
- Mayor que 0.3 y menor o igual a 0.6 → DISPERSIÓN MEDIA,
- Mayor que 0.6 → DISPERSIÓN ALTA

INDICADOR DE ASIMETRÍA (As) (redondeado a dos decimales)

Asimetría = 3*(media - mediana) / desviación estándar

```
Asimetría <- round(3*(mean(DF$VN, na.rm = TRUE) - median(DF$VN, na.rm = TRUE))/  
sd(DF$Peso, na.rm = TRUE), 2)
```

- As=0: Simétrica
- As>0: Asimétrica a la derecha, Cola a la derecha (sesgo a la derecha)
- As<0: Asimétrica a la izquierda, Cola a la izquierda (sesgo a la izquierda)



DESCRIPTORES DE POSICIÓN

Para variables categóricas ordinales (VC)

Convertir a categórica ordinal (factor)

```
DF$VC <- factor(DF$VC, levels = c("categoría1", "categoría2", "categoría3",  
"categoría4", "categoría5"), ordered = TRUE)
```

Categorías de la variable Período sin repetir sin incluir NA

```
levels(DF$VC)
```

Cantidad de períodos diferentes sin incluir NA

```
length(levels(DF$VC))
```

Moda

```
which.max(table(DF$VC)) (una forma)
```

```
mfv(DF$VC, na_rm = T) (otra forma con librería modeest)
```

Frecuencia absoluta de la Moda

```
max(table(DF$VC))
```

Categorías de la variable Período sin repetir, incluyendo NA

```
unique(DF$VC)
```

Cantidad de períodos diferentes, incluyendo NA

```
length(unique(DF$VC))
```

Cálculo del Quartil 1 = percentil 25 (Q1 = P25), quartil 2 = percentil 50 (Q2 = P50=Mediana), quartil 3 = percentil 75 (Q3 = P75)

```
quantile(DF$VC, c(0.25, 0.50, 0.75), type = 3, na.rm = TRUE)
```

Gráficos variables univariadas

Variables categóricas ordinales (VCO)

```
DF$VCO <- factor(DF2$VCO, levels = c("categoría1", "categoría2", "categoría3",  
"categoría4"), ordered = TRUE) (convierte a factor o variable categórica ordinal)
```

```
n.i1 <- table(DF$VCO) (tabla de frecuencia absoluta)
```


```
f.i1 <- prop.table(table(DF$VCO)) (tabla de frecuencia relativa)
```

```
p.i1 <- 100*f.i1 (tabla de frecuencia porcentual)
```

```
barplot(n.i1) (gráfico de barras frecuencia absoluta)
```


```
barplot(f.i1) (gráfico de barras frecuencia relativa)
```

```
barplot(p.i1) (gráfico de barras frecuencia porcentual)
```



Variables numéricas discretas (VND)

```
n.i2 <- table(DF$VND)           (tabla de frecuencia absoluta)
f.i2 <- prop.table(table(DF$VND)) (tabla de frecuencia relativa)
p.i2 <- 100*f.i2                 (tabla de frecuencia porcentual)
plot(n.i2,type="h")              (gráfico de líneas frecuencia absoluta)
plot(f.i2,type="h")              (gráfico de líneas frecuencia relativa)
plot(p.i2,type="h")              (gráfico de líneas frecuencia porcentual)
```



Variables numéricas continuas (VNC)

```
hist(DF$VNC)                     (histograma de frecuencias absolutas)
hist(DF$VNC, freq = FALSE)       (histograma de frecuencias relativas)
hist(DF$VNC, plot = FALSE)       (se muestra la información que contiene el histograma)

$breaks
[1] 6 7 8 9 10 11 12              (límites de los intervalos)

$counts
[1] 5 13 15 8 5 2                 (frecuencia absoluta de cada intervalo)

$density
[1] 0.10416667 0.27083333 0.31250000 0.16666667 0.10416667 0.04166667 (frecuencia relativa de cada intervalo)

$mids
[1] 6.5 7.5 8.5 9.5 10.5 11.5    (marca de clase)
```





Diagrama de dispersión para Variables numéricas continuas (VNC) - BOXPLOT

`boxplot(DF$VNC)`

(boxplot de manera vertical)

`boxplot(DF$VNC, horizontal = T)`

(boxplot de manera horizontal)



`boxplot(x)$out`


(listado de valores atípicos, outliers)

ANÁLISIS BIVARIADO

Entre Variable categórica (VC) y variable numérica (VN)


Usar gráficos de boxplot indexado o por categoría

`boxplot(DF$VN ~ DF$VC)`



- **Comparar variabilidad (ancho de las cajas = RIC):** Mayor ancho de las cajas, mayor variabilidad, mayor dispersión.
- **Comparar tendencia central (visualizar la mediana que está dentro de la caja) :** Mayor mediana de una categoría indica que sus datos tiende a tener un mayor valor que el resto de categorías en la variable numérica que se está comparando.

- Verificar asimetría (visualizar posición de la mediana dentro de la caja):
 - Si la mediana está en el centro de la caja es **asimétrica**
 - Si la mediana está pegada al cuartil 1 (Q1) es **asimétrica positiva** con cola hacia la derecha (pocos casos de valores altos).
 - Si la mediana está pegada al cuartil 3 (Q3) es **asimétrica negativa** con cola hacia la izquierda (pocos casos de valores bajos).
- Comparar datos atípicos, outliers o valores extremos
 - Datos cuyo valores están muy por encima del resto o del límite superior: $LS = Q3 + 1.5*RIC$
 - Datos cuyo valores están muy por debajo del resto o del límite inferior: $LI = Q1 - 1.5*RIC$



Entre Variable categórica (VC1) y variable categórica (VC2)

Tabla de contingencia o cruzada de frecuencias absolutas, en donde la totalidad de las frecuencias da por resultados cantidad total de observaciones muestrales o filas

```
Tabla0 <- table(DF$VC1, DF$VC2)
```

Tabla0

	primary	secondary	tertiary
divorced	79	270	155
married	526	1427	727
single	73	609	468

Tabla de contingencia o cruzada de frecuencias porcentuales, en donde la totalidad de las frecuencias suman 100% (redondeado a dos decimales)

```
Tabla1 <- round(prop.table(table(DF$VC1, DF$VC2))*100,2)
```

Tabla1

	primary	secondary	tertiary
divorced	1.82	6.23	3.58
married	12.14	32.93	16.77
single	1.68	14.05	10.80

Tabla de contingencia o cruzada de frecuencias porcentuales por fila, en donde las frecuencias porcentuales de cada fila suman 100% (redondeado a dos decimales)

```
Tabla2 <- round(prop.table(table(DF$VC1, DF$VC2), 1)*100,2)
```

Tabla2

	primary	secondary	tertiary
divorced	15.67	53.57	30.75
married	19.63	53.25	27.13
single	6.35	52.96	40.70

Tabla de contingencia o cruzada de frecuencias porcentuales por columna, en donde las frecuencias porcentuales de cada columna suman 100% (redondeado a dos decimales)

```
Tabla3 <- round(prop.table(table(DF$VC1, DF$VC2), 2)*100,2)
```


Tabla3

	primary	secondary	tertiary
divorced	11.65	11.71	11.48
married	77.58	61.88	53.85
single	10.77	26.41	34.67

Gráficos de interacción entre las variables categóricas (en el caso se use la **Tabla 2** o frecuencias porcentuales por fila)


Barras apiladas al 100%

```
barplot(t(Tabla2*100))
```



Barras agrupadas

```
barplot(t(Tabla2*100), beside= T)
```



Entre Variable numérica (VN_ejeY) y variable numérica (VN_ejeX)

Eliminar las filas que tienen datos faltantes en alguna de las dos variables numéricas y quedarse con aquellas filas que tienen datos completos en ambas variables numéricas

```
DF1 <- DF[!(is.na(DF$VN_ejeY) | is.na(DF$VN_ejeX)), ]
```

Coefficientes de la recta de regresión

```
Regresion <- lm(DF1$VN_ejeY ~ DF1$VN_ejeX)
```

`coef(Regresion)` → **ambos coeficientes (intercepto y pendiente)**


`coef(Regresion)[1]` → **coeficiente intercepto**

`coef(Regresion)[2]` → **coeficiente pendiente**

Gráficos de puntos o de dispersión

```
plot(DF$VN_ejeX, DF$VN_ejeY)
```

```
abline(Regresion)
```




Coefficiente de correlación de Pearson r (redondeado a dos decimales)

Cociente de la covarianza entre las variables numéricas dividida entre las desviaciones estándares de estas variables numéricas. (redondeado a dos decimales)

$$r_{XY} = \frac{S_{XY}}{S_X S_Y}$$

$$-1 \leq r \leq 1$$



```
Correlacion <- cor(DF1$VN_ejeY, DF1$VN_ejeX)
round(Correlacion, 2)
```

- Si $0 \leq |r| \leq 0.3 \rightarrow$ grado de relación o asociación entre las dos variables numéricas es **baja**.
- Si $0.3 < |r| \leq 0.6 \rightarrow$ grado de relación o asociación entre las dos variables numéricas es **media**.
- Si $|r| > 0.6 \rightarrow$ grado de relación o asociación entre las dos variables numéricas es **alta**.

Coefficiente de determinación R^2 (redondeado a dos decimales)

$$0 \leq R^2 \leq 1$$

$R^2 = r^2$ El coeficiente de determinación es el cuadrado del coeficiente de correlación lineal de Pearson.

```
Coef.Determinacion <- Correlacion^2
round(Coef.Determinacion, 2)
```

Otros códigos para limpieza:

chartr()

La función `chartr(old, new, x)` reemplaza caracteres en un texto:

- **old** = caracteres que quieres cambiar.
- **new** = caracteres que los reemplazarán.
- **x** = vector o texto donde se aplicará la transformación.

Importante: `chartr()` solo funciona **carácter por carácter**, no con cadenas largas.

Problema planteado

- A veces el **cero (0)** es mal leído como la letra **"O" mayúscula**.
- A veces el **uno (1)** es mal leído como la letra **"l" minúscula**.

Queremos transformar:

- "O" → "0"
- "l" → "1"

Ejemplo en R

Supongamos que tenemos una columna o vector con datos que contienen estos errores:

```
# Vector con errores comunes
variable_original <- c("O23", "451", "709", "1234", "O001", "25B", "3R5", "Z74", NA,
NA, "387", "496")

# Datos faltantes
sum(is.na(variable_original))
2

# Aplicamos chartr()
variable_corregida <- as.numeric(chartr(old = "Ol", new = "01", x =
variable_original))

# Mostramos resultado
variable_corregida

[1] 23 451 709 1234 1 NA NA NA NA NA 387 496

# Datos faltantes
sum(is.na(variable_corregida))
5
```

Por tanto, se incrementó o añadió **3** datos faltantes al realizar la limpieza.

Otra manera de calcular el incremento de datos faltantes luego de la limpieza.

```
sum(!is.na(variable_original) & is.na(variable_corregida))
```

Calculando nuevo tamaño efectivo de la muestra

```
n_muestra <- sum(!is.na(variable_corregida))
```

```
n_muestra
```

```
7
```

str_split_fixed() de la librería stringr

- Es una función de **stringr** que divide (separa) cadenas de texto usando un **separador** (por ejemplo: espacio, coma, guion, etc.).
- A diferencia de **str_split()**, que devuelve **listas** (donde cada elemento puede tener distinta longitud), **str_split_fixed()** siempre devuelve una **matriz (matrix)** con **n columnas fijas**.

Es decir, obligamos a que la separación tenga un **número exacto de partes**. Si no hay suficientes partes, rellena con "" (texto vacío).

Sintaxis

`str_split_fixed(string, pattern, n)`

- `string` = vector de textos a dividir.
- `pattern` = patrón o separador (ejemplo: " ", ",", "-", "-").
- `n` = número de columnas que queremos obtener.

Un **ejemplo con fechas** en un `data.frame`, usando `str_split_fixed()` para separar la fecha en **año, mes y día**.

```
# Cargar librería
library(stringr)

# Creamos un data.frame con fechas en formato AAAA-MM-DD
df <- data.frame(ID = 1:4,
                  Fecha = c("2025-10-03", "2024-12-25",
                           "2023-01-01", "2022-07-15"),
                  stringsAsFactors = FALSE)

# Usamos str_split_fixed para dividir en 3 columnas: Año, Mes, Día
separado <- str_split_fixed(df$Fecha, "-", 3)

# Agregamos las columnas al data.frame
df$Anio <- separado[,1]
df$Mes  <- separado[,2]
df$Dia  <- separado[,3]

# Mostramos resultado
print(df)
```

	ID	Fecha	Anio	Mes	Dia
1	1	2025-10-03	2025	10	03
2	2	2024-12-25	2024	12	25
3	3	2023-01-01	2023	01	01
4	4	2022-07-15	2022	07	15

De esta forma:

- La columna `Fecha` queda intacta.
- Se crean tres columnas nuevas: `Anio`, `Mes`, `Dia`.

Un **ejemplo práctico** con un `data.frame` en R donde una columna tiene el **nombre completo** y la separamos en **dos columnas nuevas: Nombre y Apellido**

```
# Cargar librería
library(stringr)

# Creamos un data.frame de ejemplo
df <- data.frame(ID = 1:4,
                  NombreCompleto = c("Ana López", "Carlos Pérez",
                                     "María Gómez", "Luis Torres"),
                  stringsAsFactors = FALSE)

# Usamos str_split_fixed para dividir en dos columnas
separado <- str_split_fixed(df$NombreCompleto, " ", 2)

# Agregamos las columnas nuevas al data.frame
df$Nombre <- separado[,1]
df$Apellido <- separado[,2]

# Mostramos resultado
print(df)
```

	ID	NombreCompleto	Nombre	Apellido
1	1	Ana López	Ana	López
2	2	Carlos Pérez	Carlos	Pérez
3	3	María Gómez	María	Gómez
4	4	Luis Torres	Luis	Torres

varwidth = TRUE en la función boxplot()

Cuando haces un **boxplot de una variable numérica agrupada por categorías**, cada caja representa la distribución de la variable numérica en un grupo.


- Si **no usas** `varwidth`, todas las cajas tienen **el mismo ancho**, sin importar cuántas observaciones haya en cada categoría.
- Si **usas** `varwidth = TRUE`, el ancho de cada caja será proporcional a la **raíz cuadrada del número de observaciones en cada grupo**.

Esto ayuda a **comparar gráficamente la cantidad de datos por categoría**, además de la dispersión de la variable numérica.

```
# Creamos un data.frame con una variable numérica y una categórica
set.seed(123)
df <- data.frame(
  Categoria = rep(c("A", "B", "C"), times = c(10, 30, 50)), # tamaños distintos
  Valor = c(rnorm(10, mean = 5), # 10 datos en A
            rnorm(30, mean = 6), # 30 datos en B
            rnorm(50, mean = 7)) # 50 datos en C
)

# Boxplot normal (todas las cajas con mismo ancho)
boxplot(Valor ~ Categoria, data = df,
        main = "Boxplot sin varwidth")

# Boxplot con varwidth = TRUE (ancho proporcional al tamaño del grupo)
boxplot(Valor ~ Categoria, data = df,
        varwidth = TRUE,
        main = "Boxplot con varwidth = TRUE")
```



Interpretación

En el boxplot normal, las cajas de A, B y C tienen el mismo ancho, aunque A tiene solo 10 observaciones y C tiene 50.

En el boxplot con `varwidth = TRUE`:

La caja de C aparece más ancha porque tiene más datos.

La de A es más angosta porque tiene pocos datos.

B queda en un ancho intermedio.